


Распределённые БД, Data Lakes и консенсус

Архитектура данных в банке и финтехе: где система записи, где система инсайта, и где между ними проходит граница консенсуса.



ЗАЧЕМ ЭТО БАНКУ

Цена ошибки в архитектуре данных — это не миллисекунды, а сломанные инварианты.



Балансы и платежи

Точность до копейки.
Идемпотентность повторов.
Согласованность остатка
после commit.



Антифрод

Решение за десятки
миллисекунд. Сотни миллионов
событий в день. Действие —
живое.



Риск-отчётность

BCBS 239 · RDARR. Полнота,
точность, своевременность,
воспроизводимость агрегатов.



Аудит и комплаенс

GDPR · DORA. Lineage, retention,
masking — часть архитектуры,
а не последний слайд.

Архитектура данных — это не вопрос «какая БД лучше». Это вопрос «где источник истины для **денег**, для **событий** и для **отчётности**».


ОСНОВНОЙ ВОПРОС ЛЕКЦИИ

System of record $\neq$ System of insight

AUTHORITATIVE WRITES



ANALYTICAL READS



- Точечные операции, короткие транзакции
- Сильные инварианты денег
- p99 — единицы и десятки миллисекунд


- Replay истории, batch + stream
- Joins, ML-фичи, BI, регуляторные витрины
- p99 — секунды и минуты

НЕ БРЕНДЫ — РОЛИ

Distributed DB · Data Lake · Lakehouse

DISTRIBUTED DB

Authoritative writes




SHARD · REPLICAS

Транзакции, индексы, point reads. Ledger, balances, idempotency.

Анти-паттерн: тянуть сюда весь BI и ML.

DATA LAKE

Дешёвый append-only архив



Файловый substrate. Raw events, immutable history, backfill zone.

Анти-паттерн: делать источник истины для денег.

LAKEHOUSE

Lake + ACID + governance

ACID · SCHEMA · CDF · TIME TRAVEL




MERGE, upsert, time travel. Risk marts, governed analytics, ML features.

Анти-паттерн: подменять им горячий transaction path.

КРИТЕРИЙ	DISTRIBUTED DB	DATA LAKE	LAKEHOUSE
Тип доступа	Point R/W	Batch-scan	Batch + stream + SQL
Транзакционность	ACID	Файлы — нет	ACID-надстройка

СЛИЯНИЕ НЕСКОЛЬКИХ БД В ЕДИНЫЙ LAKEHOUSE


Не nightly dump — управляемый поток изменений.



CDC VS DUAL WRITE

Outbox переносит атомарность из распределённой плоскости в локальную.


DUAL WRITE · ОПАСНО



— Потерянные или дубликатные события

— Расхождение OLTP и downstream
ЛЕКЦИЯ · 2026

OUTBOX + CDC · НАДЁЖНО




— Локальная атомарность вместо распределённой

— Транзакционный порядок сохраняется


MEDALLION И GOVERNANCE

Качество и governance растут по слоям.
У каждого слоя свой контракт.



ЗАЧЕМ ФИНАНСОВЫМ СИСТЕМАМ CONSENSUS

Чтобы не врать под отказами. Единый порядок принятия решений — и при падении узлов тоже.




- **Кворум = большинство.** Из 5 узлов 3 должны согласиться — тогда запись считается закоммиченной.
- **Безопасность ≠ доступность.** Если большинство недоступно — лучше отказать, чем принять расходящиеся записи.
- **Replicated state machine.** Все узлы исполняют одну и ту же последовательность команд.
- **Без consensus — split brain.** Два ledger'а с расходящимся балансом одного клиента.

Финансовая интуиция: **consensus** — это не «быстрее», это «корректнее под отказами». За него платят latency.

RAFT — СИЛЬНЫЙ ЛИДЕР И REPLICATED LOG

Лидер принимает, реплицирует, коммитит. Простой явный поток.

**Election.**

Кандидат набирает большинство голосов в term.

Log replication.

AppendEntries; commit после quorum acks.


Safety.

Закоммиченная запись уже не откатится.

В проде: CockroachDB, Kafka KRaft, etcd.

PAXOS — СОГЛАСОВАНИЕ ОДНОГО ЗНАЧЕНИЯ

Three roles, two phases, one chosen value.



- **Proposer** предлагает значение v с номером n .
- **Acceptors** обещают не принимать предложения с меньшим n .
- Если большинство acceptors приняло (n, v) — значение **chosen**.
- **Learners** узнают результат и применяют его к state machine.
- Multi-Paxos: серия экземпляров → replicated log → один **distinguished proposer** для прогресса.

В проде:

Cassandra LWT — linearizable CAS

Google Spanner — Paxos groups + TrueTime

Megastore, Chubby — Google internals

RAFT И PAXOS В ИНЖЕНЕРНОЙ ПРАКТИКЕ


Семейство одно. Дидактика и эргономика — разные.

КРИТЕРИЙ	RAFT	PAXOS (MULTI-PAXOS)
Базовая идея	Strong leader управляет replicated log	Согласование одного значения большинством acceptors
Учебная подача	Проще: election → replication → safety	Концептуально богаче, исторически первичен
Лидерство	Явное и центральное	Distinguished proposer в практике
Практические системы	CockroachDB · Kafka KRaft · etcd · Consul · TiKV	Cassandra LWT · Google Spanner · Chubby · Megastore
Сильная сторона	Понятен инженеру и студенту	Тонкая настройка прогресса и безопасности
Частая ошибка	«Raft автоматически быстрее»	«Paxos только теория»

Оба алгоритма решают одну задачу — **replicated state machine**. Выбор определяется не скоростью, а продуктом, экосистемой и операционной зрелостью команды.

СПЕКТР ГАРАНТИЙ


Какие гарантии нужны на самом деле?



Должна ли витрина расходов клиента быть так же строга, как booking в ledger?
Почти всегда нет.

ЦЕНА ГАРАНТИЙ

Сильнейшие гарантии не бесплатны. И их не нужно покупать там, где задача того не требует.

**Round trips.**

Каждый кворум стоит сетевой ходки.

Координация.


LWT и cross-region это два-этапные протоколы.

Operational complexity.

Backpressure, ISR, retry, observability.

AUTHORITATIVE LEDGER + АСИНХРОННЫЙ LAKEHOUSE

Деньги — в ledger. Инсайт — в lakehouse. Граница — CDC-контракт.




УЧЕБНЫЕ ДАННЫЕ · TXN

TXN_ID	ACCT	AMOUNT	TYPE
T-1001	ACC-01	-1 250.00	card_auth
T-1002	ACC-01	-1 250.00	clearing
T-1003	ACC-77	+85 000.00	salary

- Trade-off.**
Lakehouse как ledger — взорвёт commit path. OLTP как BI — съест ресурсы critical path.
- Контракт.**
OLTP — деньги. CDC — транспорт и replay. Lakehouse — enrichment и аналитика.

REAL-TIME FRAUD · DETECTION VS LEARNING

Максимум correctness — в пути решения.
Максимум полноты — в пути анализа.



УЧЕБНЫЕ СОБЫТИЯ · ФРАГМЕНТ СКОРИНГА

EVENT	AMT	DIST KM	FAIL 24H	ACTION
F-001	145 000	780	3	review
F-002	890	2	0	allow

Skip-rule оптимизация.


Простое правило с высокой уверенностью пропускает тяжёлую модель → −150 ms на p99.

Online ≠ Offline.

В hot path — только то, что укладывается в SLA. Остальное — в lakehouse.

GOVERNED ANALYTICS · РИСК · ОТЧЁТНОСТЬ

Lakehouse оценивается не только по скорости ETL.



УЧЕБНАЯ ВИТРИНА · RISK EXPOSURES

ID	СЕГМЕНТ	ПРОДУКТ	EAD МЛН	PD	LGD
R-001	retail	mortgage	420	0.018	0.22
R-002	SME	overdraft	95	0.067	0.41
R-003	corporate	trade fin	310	0.031	0.28

- Bronze.** Raw, immutable, replay-zone.
- Silver.** Валидация и стабильные определения.
- Gold.** Definitions, не меняющиеся между релизами.
- Anti-pattern.**
Federated ownership без centralized guardrails — управленческий долг.

ТРИ ЛАБОРАТОРНЫХ БЛОКА

Что попробовать руками.

LAB · 01

CDC и transactional outbox




Цель. Понять, почему dual write опасен и как outbox + CDC чинит атомарность.

Стек. PostgreSQL, Debezium, Kafka, Docker Compose.

Результат. В outbox-варианте событие неотделимо от commit; в naive dual write — drift.

LAB · 02

Flink и семантики доставки



Цель. Понять разницу exactly-once и at-least-once в stateful обработке.

Стек. Kafka, Flink, генератор card_txn.

Результат. Перезапуск job: exactly-once сохраняет агрегаты, at-least-once «раздувает» суммы.

LAB · 03

Medallion, CDF и time travel



Цель. Построить воспроизводимый analytical layer из потока изменений.

Стек. Spark + Delta Lake или Databricks; альтернативно Snowflake.

Результат. Bronze→Silver→Gold с CDF + восстановление прошлой версии через time travel.

Все три воспроизводимы локально через Docker Compose или в managed-облаке без изменения логики.

ЧЕК-ЛИСТ ДЛЯ ЛЮБОЙ НОВОЙ СИСТЕМЫ ДАННЫХ

Выбирайте не продукт. Выбирайте свойства.

- 1 Какой инвариант защищаем?**
Деньги, уникальность, цепочка событий, версия записи. Если нет инварианта — нет требований к согласованности.
- 2 Где источник истины?**
Один и только один. Всё остальное — derived. Это пишется на первой странице design doc.
- 3 Какая нужна latency?**
Миллисекунды для денег. Секунды для BI. Минуты для отчётности. Не покупайте, что не требуется.
- 4 Нужен ли replay и audit?**
Если да — append-only лента и lineage с первого дня. Регуляторика не ретроактивна.

«Если есть ответы на эти четыре вопроса — технология подберётся почти сама. Если нет — никакая модная технология не спасёт».